

UdK Infoklasse: Datenjournalismus

Sommersemester 2026

Julia Barthel

April 2026

Table of contents

1	“Geschichten in Daten – finden und erzählen”	1
1.1	Was ihr am Ende könnt	1
1.2	Orientierung	1
1.3	Über dieses Material	2
2	Überblick	3
2.1	→ Was machen wir in diesem Seminar?	3
2.2	Semesterplan	4
2.3	Eckpunkte – Erwartungen	4
3	Workflows & Werkzeuge	7
3.1	Beispiel: “Wie Europa seinen Solarboom finanziert”	7
3.2	Storytelling – Die Grundlagen	8
3.2.1	1. Was ist eine Geschichte?	9
3.2.2	2. Was ist eine Nachricht?	10
3.3	Grundprinzipien der Datenarbeit	11
3.3.1	Das Ding mit der Objektivität...	11
3.4	Wie plane ich ein Datenprojekt?	13
3.4.1	Beispielablauf	13
3.5	☒ Übung: Hundebiss-Statistik Berlin 2024	14
3.5.1	1. ☒ Datenrecherche : Welche Daten gibt es?	14
3.5.2	2. ☒ Quellenkritik : Was können die Daten sagen, was nicht?	14
3.5.3	3. ☒ Hypothesen finden : “Drehbuch der Recherche”	14
3.5.4	4. ☒ Daten analysieren : Hypothesen prüfen	15
3.5.5	5. ☒ Daten einordnen lassen : Interviews & Hintergrund	15
3.5.6	6. ☒ Veröffentlichung planen : Grafiken entwerfen, texten	15
3.5.7	7. ☒ Ergebnisse verifizieren : mindestens 4-Augen-Check	15
3.6	Datenquellen	16
3.6.1	Welche Daten dürfen wir benutzen?	16
3.7	☒ Übung: Hundebiss-Statistik Rheinland-Pfalz 2024	17
3.8	Tools, um Tabellen aus PDFs zu extrahieren	17
3.9	Wie finde ich Tools?	17
3.10	☒ Übung: Hundebiss-Statistik Berlin über die Jahre	17

3.10.1	Schritt 1: Links zu csv-Dateien sammeln	18
3.10.2	Schritt 3: R installieren	18
3.10.3	Schritt 4: RStudio installieren	18
3.10.4	Schritt 5: R-Projekt anlegen	18
3.10.5	Schritt 6: Code kopieren, ausführen, glücklich werden . . .	18
3.11	Langeweile?	19
3.11.1	Weiterlesen / -hören	19
3.11.2	Ausprobieren	19
4	Daten aufbereiten	21
5	Ich habe Daten – was jetzt?	23
5.1	Beispiel: “Warum sich immer mehr Menschen krankmelden”	23
5.2	Übung: Musik – US-Charts	24
5.3	Übung: Wein	26
5.4	Übung: Stadtbaumkampagne Berlin	27
5.5	Wo kann man nach Daten stöbern?	28
6	Daten sammeln	29
7	Ich habe eine Frage, aber keine Daten	31
7.1	Beispiel: “Freie Plätze sind rar: Die Lage in bayerischen Frauenhäusern”	31
7.2	Übung: Defekte Aufzüge / Rolltreppen in München	32
7.3	Übung: Drogerie-Produkte	33
7.4	Übung: Windkraft Bayern	34
8	Ein Projekt strukturieren	35
9	Heute geht’s um eure Projekte!	37
9.1	1. Geschichten in Daten finden – Pfade zum Erfolg	37
9.2	2. Zeitmanagement & Dokumentation	37
9.2.1	Dokumentation – Gedanken mitschreiben	38
9.3	3. Kleine Datenquellenkunde	39
9.3.1	Wer könnte das wissen? – Datenquellen finden	39
9.3.2	offene Daten	39
9.3.3	selbst erhobene Daten	39
9.3.4	exklusive Daten	39
9.3.5	gescrapte Daten	40
9.3.6	Informationsfreiheitsgesetz (IFG)	40
9.4	Parlamentarische Dokumente (Drucksachen)	40
10	Projekt ist fertig – wir blicken zurück	43
10.1	Wann ist ein Projekt abgeschlossen?	43
10.2	Besser werden	43
10.2.1	Die Sicht von außen: Feedback geben	44
10.2.2	Die Sicht von innen: Manöverkritik	44

11 Webscraping	45
11.1 Webscraping – was ist das?	45
11.2 1. Informationen sind auf einer Webseite verfügbar.	46
11.2.1 Tabellen	46
11.2.2 Andere, klar definierte Elemente	47
11.2.3 Mehrere Webseiten (mit gleicher Struktur)	47
11.3 2. Informationen sind nur teilweise sichtbar, müssen nachgeladen werden.	49
11.3.1 Mehr laden durch Scrollen	49
11.3.2 Mehr laden durch Klick auf Button	49
12 Die Tools im Überblick	51
12.1 Wichtige Punkte	51
13 Kartendaten	53
13.1 Webscraping – was ist das?	53
14 Storytelling	55
15 Dramaturgie	57
16 Text	59
17 References	61

Chapter 1

“Geschichten in Daten – finden und erzählen”

Worum es geht

Gesellschaftlich relevante Geschichten in Daten finden und verständlich erzählen – das ist die Kernaufgabe des Datenjournalismus. Was dabei “Daten” sind, ist im 21. Jahrhundert breit gefasst: Von Informationen im Web über digitale Alltagsdokumente wie PDFs, JPGs oder Word-Dateien. Der Kurs schafft technische und methodische Grundlagen, um zielgerichtet datenjournalistische Geschichten zu entwickeln und Daten mit passenden Tools auszuwerten, vom Browser bis zum eigenen Code. (Keine Vorkenntnisse nötig, Interesse ist die einzige Voraussetzung.)

1.1 Was ihr am Ende könnt

1. Datenjournalistische Fragestellungen entwickeln und Umsetzung planen
2. Spickzettel benutzen und Hilfe suchen
3. Daten verarbeiten: Input – Blackbox-Gerödel* – Output (visualisierungsfertig)
4. besser mit eurem Computer und dem Internet umgehen

* dafür lernen wir einen ganzen Haufen Tools und Techniken kennen

1.2 Orientierung

Diese Dokumente	Semesterplan	Daten
x	x	x

1.3 Über dieses Material

Dieses Seminarmaterial wurde gebaut mit Quarto, für die Webansicht mit dem Theme “Yeti”. Die Grafiken kommen von undraw.com und dürfen von allen für alles frei verwendet werden. Vielen Dank dafür!

Und als Notizzettel: Die Fokus-Farbe ist #008cba.

Chapter 2

Überblick

2.1 → Was machen wir in diesem Seminar?

Wir lernen mit vielen praktischen Übungen und kompaktem theoretischem Input, wie man Geschichten in Daten findet. Dazu lernen wir unsere Rechner und das Internet besser kennen. Insbesondere schauen wir uns an, wie und wo man Daten findet, wie man eigene Datensätze erstellt und wie man Erkenntnisse aus Daten kommuniziert.

Wichtig: Wir versuchen uns auch an Visualisierungen. Weil es dazu aber viele andere Kurse gibt, konzentrieren wir uns darauf, die richtige Visualisierung auszuwählen und zu lernen, wie wir Daten dafür strukturieren.



☒ **Das Wissen ist da** – ich helfe euch dabei, es zu verstehen und anwenden zu können.

☒ **Die Idee:** Wir nutzen die Zeit im Seminarraum möglichst gut, damit ihr rausgeht und die Grundlagen sicher beherrscht.

☒ **Wer mehr will:** Ich empfehle euch Ressourcen und Material, um noch tiefer einzusteigen.

2.2 Semesterplan

Datum	Thema	Link
16.04.2026	Einführung	Kapitel Daten
23.04.2026	Workflow & Werkzeuge	Kapitel Daten
30.04.2026	Ich habe Daten, was jetzt?	Kapitel Daten
07.05.2026	Ich habe eine Frage, aber keine Daten – was jetzt?	Kapitel Daten
21./22.05.2026	Projektblock 1 – eigene Fragestellung	Kapitel Daten
04.06.2026	Feedback	Kapitel Daten
11.06.2026	Webscraping	Kapitel Daten
18.06.2026	Kartendaten	Kapitel Daten
25.06.2026	Storytelling	Kapitel Daten
02.07.2026	Datenjournalistische Dramaturgie	Kapitel Daten
09.07.2026	Text	Kapitel Daten

2.3 Eckpunkte – Erwartungen

In der Einführungssitzung haben wir darüber gesprochen, was ihr euch wünscht – daran werde ich das Angebot ausrichten.

Hauptziel des Seminars



Skills erwerben

Portfolio anlegen

Kompetenzen



Recherche

Storytelling

Software-Skills



Tools

Code-Profis

Quellen



Zahlen/Tabellen

Multimedia/Dokumente

Zeitliche Ressourcen

▼
im Seminar
außerhalb

Soziale Ressourcen

▼
Gruppenarbeit
Einzelarbeit

Chapter 3

Workflows & Werkzeuge

Worum es heute geht

- **Theorie:**
 - Grundprinzipien der Datenarbeit
 - Grundlagen Zeit- und Projektplanung
 - Datenquellen, Lizenzen & Open Data
- **Praxis:**
 - Tabellarische Dateiformate in Tabellenkalkulation laden und aufbereiten
 - Fragen an einen Datensatz entwickeln
 - Tabelle aus PDF extrahieren
- **Technik:**
 - Dateiformate: csv, Tabellen in PDF
 - Tools: LibreOffice, Datawrapper, Tabula, (Firefox-)Developertools, Terminal, RStudio
- **Datenquellen:**
 - Hundebiss-Statistik Berlin & Rheinland-Pfalz

3.1 Beispiel: “Wie Europa seinen Solarboom finanziert”

von Kira Schacht / Deutsche Welle ☒ Deutsch ☒ English

**Fragen zum Lesen:**

1. Was gefällt dir (nicht)? Warum?
2. Was interessiert dich? Was langweilt dich?
3. Wenn du fertig bist: Was ist hängen geblieben?

Was man daraus lernen kann:

- Wir Menschen lieben Geschichten – vor allem über Menschen. Daten können uns zu diesen interessanten Menschen und ihren Geschichten führen.
- Für unterschiedliche Aussagen eignen sich unterschiedliche Arten von Grafiken.
- Grafiken müssen in den Text eingebunden sein. Sie sind Teil des Textes, kein “nettes Extra”. (Auch im Sinne der Barrierefreiheit ist die zentrale Aussage einer Grafik aber auch im Text.)

3.2 Storytelling – Die Grundlagen



3.2.1 1. Was ist eine Geschichte?

Gute Frage, hierzu könnte man ein eigenes Studium machen. Oder man nimmt die Abkürzung und liest ein Buch wie beispielsweise “Storytelling” von Sven Preger, der vor allem Audio-Geschichten erzählt, z.B. für den Deutschlandfunk oder den WDR. Darin steht:

“Eine Geschichte besteht in aller Regel aus drei Basis-Elementen: eine aktiv-handelnde Person, ein konkretes Ziel und (etliche) Widerstände.

Es gibt viele Möglichkeiten, diese Basis-Elemente zu strukturieren. In der Erzähltheorie gibt es verschiedene Modelle, wie Handlungen strukturiert sein können. Ganz klassisch, wie in den Dramen von Goethe und Schiller lernt man in der Schule oft den Aufbau, der sich bis auf Sophokles im antiken Griechenland zurückführen lässt: auslösendes Moment im ersten Akt, Zuspitzung des Konflikts im zweiten Akt, Herausforderung im dritten, Höhepunkt im vierten und dann die Auflösung im fünften Akt. Hier eine Abbildung aus einem mehr oder weniger zufällig ausgewählten Lehrbuch (Harzer 2017, S. 197):





Abb. 6: Dramenstruktur nach Freytag

Insbesondere in der Filmindustrie ist mittlerweile aber auch das Konzept der “Heldenreise” verbreitet, hier dargestellt von Sven Preger in seinem Buch “Storytelling” (S. 74):

DIE HELDENREISE**Abb. 3.2** Die Heldenreise (eigene Darstellung)

Das ist natürlich ganz schön detailliert und komplex. Um die eigene Geschichte zu strukturieren, schlägt Sven Preger deshalb, kurz und prägnant, einen Erzählsatz vor:

“A (der Protagonist) will B (seine Absicht/sein Ziel), weil er C (die Motivation), stößt aber auf D (Hindernisse). Diese Hindernisse muss der Protagonist überwinden, oder es zumindest versuchen. Der Erzählsatz ist damit der Kompass, an dem sich die Geschichte ausrichtet.”

3.2.2 2. Was ist eine Nachricht?

Jetzt soll eine Geschichte ja in unserem Fall nicht fiktional sein, sondern vor allem Wissen vermitteln. Aber was ist überhaupt relevant, und damit vermittelenswert?

Im Journalismus gibt es unterschiedliche Darstellungsformen. Grob unterteilt man in informierende und meinungsäußernde Formen. Informierend sind Nachrichten, Reportagen, Interviews oder Korrespondentenberichte. Meinungsäußernd ist zum Beispiel der Kommentar.

Eine Nachricht sollte möglichst viele der sieben wichtigen Fragen beantworten – diese können wir verwenden, um Fragen an unsere Daten zu entwickeln:

- **Wer?** (Wer hat am meisten...? Wer hat am wenigsten...?)
- **Was?** (Was ist anders als vielleicht angenommen?)
- **Wo?** (Wo häufen sich die Ereignisse?)
- **Wann?** (Wann hat sich etwas verändert? Wie hat sich etwas entwickelt?)
- **Wie?** (Wie hängen x und y zusammen?)
- **(Warum?)**
- **Woher?** (Woher kommen die Daten? Wer hat sie mit welchem Interesse erhoben?)

(siehe Einführung in den praktischen Journalismus)

Praktische Probe, ob eine Nachricht relevant ist

Der “Küchenzruf”: Eine Zusammenfassung der zentralen Aussage in maximal zwei Sätzen. Der Begriff wurde vom Stern-Redakteur Henri Nannen geprägt und durch eine beispielhafte Situation erklärt, in der ein gewisser Hans im Esszimmer den ‚Stern‘ liest, während „Frau Grete“ in der Küche „sich die Schürze umbindet, um sich für den Abwasch vorzubereiten“. Nach „beendigter Lektüre“ ruft Hans seiner Grete in die Küche zu: „Mensch Grete, die in Bonn spinnen komplett! Die wollen schon wieder die Steuern erhöhen!“ Das würde man heute hoffentlich anders erklären, aber das Prinzip bleibt das gleiche:
“Hey, hast du schon gehört? ...!”

3.3 Grundprinzipien der Datenarbeit



1. **Wir verändern niemals Originaldaten.**
2. Wir arbeiten möglichst **nachvollziehbar**, also möglichst nah am Original.
3. Wir **dokumentieren** unsere Arbeitsschritte, um sie reproduzieren zu können.

→ Wir rechnen also mit Fehlern und arbeiten so, dass wir sie finden und korrigieren können.

3.3.1 Das Ding mit der Objektivität...

Die Vorstellung, Journalismus müsse “neutral” sein, ist weit verbreitet. Tatsächlich steht im Medienstaatsvertrag aber kein Wort von Neutralität in Bezug auf den Journalismus. Stattdessen sind die öffentlich-rechtlichen Medienanstalten verpflichtet zur “unabhängigen, sachlichen, wahrheitsgemäßen und umfassenden Information und Berichterstattung”. (Kann man nachlesen oder in sechs Minuten hier nachhören.)

Ein verbreitetes Zitat stammt von dem Fernseh-Journalisten Hanns Joachim

Friedrichs: “Einen guten Journalisten erkennt man daran, dass er sich nicht gemein macht mit einer Sache, auch nicht mit einer guten Sache.” Das kann ohne Kontext aber leicht missverstanden werden und wird immer wieder diskutiert. Die beste Einordnung liefert ein Text von Uebermedien. Der Kern: Journalist*innen müssen berichten über alles, was in der Welt passiert. Und dürfen sich davon nicht überrollen lassen. Sonst könnten sie ihren Job nicht machen.

Wie sich Journalist*innen, insbesondere im öffentlich-rechtlichen Rundfunk, äußern dürfen, wird immer wieder angegriffen. Aktuell beispielsweise in Bayern mit Reformplänen für ein neues Rundfunkgesetz. Das will unter anderem im Prinzip eine “Informationsquote” fürs Fernsehen vorschreiben. Aber auch die Zivilgesellschaft soll sich möglichst nicht “politisch” äußern – das Demokratieförderprogramm soll gerade unter Leitung von Ministerin Karin Prien “in die Mitte” gerückt werden. Hier gut erklärt in einem Artikel der Zeit. Was bleibt: Alleine die permanente Unterstellung, dass Institutionen, die sich für ein vielfältiges und friedliches Miteinander einsetzen, “links” sind, verunsichert.

Umso wichtiger ist gute Arbeit – und erklären, was gute Arbeit ist. Im Kontext von Daten heißt das:


Leitlinien

Es gibt viele allgemein akzeptierte Regeln für zuverlässige Recherche. Hier sind ein paar:


- Bemühe dich, alle relevanten Quellen zu finden.
- Lasse keine Quelle unter den Tisch fallen, nur weil sie etwas anderes behauptet, als du dir erhofft hast.
- Mache deinen Quellen transparent.
- Zitiere korrekt und ohne Aussagen aus dem Kontext zu reißen.
- Formuliere deine Erkenntnisse so deutlich und konkret wie möglich.
- Weise ehrlich darauf hin, was du nicht herausfinden konntest.
- Lasse einen unabhängigen Experten über deine Arbeit schauen, bevor du sie publizierst.

(vgl. Sengers and Hunter 2018, S. 20f)

Denn ganz wichtig: Daten brauchen Kontext. Und der muss mitgedacht werden! Sonst wird es unangenehm, wie für Innenminister Alexander Dobrindt 2025 zum Verfassungsschutzbericht. Der Bericht von T-Online zeigt gut, wie zwei gleich aussehende Grafiken unterschiedliche Skalen hatten:



3.4 Wie plane ich ein Datenprojekt?



3.4.1 Beispielablauf

0. **Idee:** Irgendjemand hat eine Idee...
1. **Datenrecherche:** Welche Daten gibt es?
2. **Quellenkritik:** Was können die Daten sagen, was nicht?
3. **Hypothesen finden:** "Drehbuch der Recherche"
4. **Daten analysieren:** Hypothesen prüfen
5. **Daten einordnen lassen:** Expert*innen suchen, Interviews und Hintergrundgespräche führen
6. **Veröffentlichung planen:** Grafiken entwerfen, texten
7. **Ergebnisse verifizieren:** mindestens 4-Augen-Check

3.5 ☒ Übung: Hundebiss-Statistik Berlin 2024



“Gestern hat ein Hund einen Menschen schwer verletzt. Passiert sowas eigentlich öfter?”

3.5.1 1. ☒ Datenrecherche: Welche Daten gibt es?

Suchtipps anzeigen

- Suchmaschine → Website Berlin
- govdata.de → Datensatz zum Download

3.5.1.1 Wir mögen CSV-Dateien

- größter Vorteil: klein
- sehr schlicht, können eigentlich alle Programme öffnen
- Nachteil: speichern keinen Kontext

3.5.2 2. ☒ Quellenkritik: Was können die Daten sagen, was nicht?

- Was sind die aktuellsten verfügbaren Daten – in welchen Zyklen werden frische Daten veröffentlicht?
- Könnte es ein, dass bis zur geplanten Veröffentlichung aktualisierte Daten bereitstehen?
- Wie zuverlässig sind die Daten – kommen sie möglichst direkt von der Erhebungsstelle?
- Was wissen wir über die Daten – gibt es Kontext-Informationen?

3.5.3 3. ☒ Hypothesen finden: “Drehbuch der Recherche”

- Welche Hunde haben die meisten Menschen verletzt?
- Welche Hunde haben im Verhältnis zu allen Menschen, die sie verletzt haben, die meisten Menschen *schwer* verletzt?
- Welche Hunde, die nicht als gefährlich gelten, haben mehr Menschen verletzt, als solche, die als gefährlich gelten?

3.5.4 4. ☒ Daten analysieren: Hypothesen prüfen


- Hier: Summen bilden, Anteile ausrechnen

3.5.5 5. ☒ Daten einordnen lassen: Interviews & Hintergrund

- Gibt es einen Kontakt zur datenveröffentlichenden Stelle – wer ist fachlich zuständig?
- Welche Expert*innen beschäftigen sich noch mit den Daten und können in einem Hintergrundgespräch die Methodik einordnen?

3.5.6 6. ☒ Veröffentlichung planen: Grafiken entwerfen, texten

- Was ist interessant?



- Die richtige Grafik zur Aussage finden:
 - ☒ The Visual Vocabulary, developed and published by Financial Times (FT)
 - ☒ Datawrapper: “A friendly guide to choosing a chart type”
 - ☒ Storytelling with Data: “SWD Chart Guide”
- Empfehlung für Visualisierungen: Datawrapper

3.5.7 7. ☒ Ergebnisse verifizieren: mindestens 4-Augen-Check

- Aussagen auf Plausibilität prüfen
- dokumentierte Schritte nachvollziehen

Wie lange dauert's denn nun?

Inoffizielle Faustregel 📏: Doppelt so lange, wie du denkst + 1 Tag.

3.6 Datenquellen



- Statistisches Bundesamt
- Statistische Landesämter
- govdata.de – Daten von Behörden, Kommunen, etc.
- Drucksachen Bundestag
- Google Dataset Search

3.6.1 Welche Daten dürfen wir benutzen?

“Open Data” ist ein feststehender Begriff seit vielen Jahren. In Deutschland gibt es dafür verschiedenste Regelungen, aber keine umfassende Verpflichtung, dass öffentliche Einrichtungen offene Daten verfügbar machen müssen. Dabei bedeutet das, dass man Daten frei nutzen kann, ohne weitere Einschränkungen:

“Open means anyone can freely access, use, modify, and share for any purpose (subject, at most, to requirements that preserve provenance and openness).”

<https://opendefinition.org/>

In der Praxis ist das in Deutschland oft anders umgesetzt und die datenveröffentlichende Stelle verlangt ihre Nennung. Das regelt die jeweilige Lizenz:

- “Gemeinfreiheit” CCO
- CC BY 4.0
- “Datenlizenz Deutschland” BY, Zero

govdata.de rät zu CC-Lizenzen

3.7 ☒ Übung: Hundebiss-Statistik Rheinland-Pfalz 2024

Suchtipps anzeigen

- Google-Suche: “innenministerium rheinland pfalz hund filetype:pdf 2024”
- ☒

Beispiel-Bericht anzeigen

“Zahl der Verletzten durch Hundebisse in Berlin zurückgegangen” rbb24.de

3.8 Tools, um Tabellen aus PDFs zu extrahieren

- tabula Download oder gehostet (**öffentlich!!**)
- mit der Programmiersprache Python: camelot / excalibur
- für komplexere Dokumente, Python-Kenntnisse nötig: docling

3.9 Wie finde ich Tools?

- **alternativeto.net**: Einstellungen: “Open Source” + eigenes Betriebssystem
- **github.com**: Code-Plattform (gehört Microsoft), die kuratierte “awesome”-Listen hat, z.B. <https://github.com/topics/awesome-list>
- abgucken bei anderen:
 - Deutsche Welle Datenteam,
 - Bayerische Digitalagentur Byte Bayern
 - 30DayMapChallenge, 30DayChartChallenge

3.10 ☒ Übung: Hundebiss-Statistik Berlin über die Jahre



Wir erinnern uns: Auf govdata.de gab es Datensätze bis 2016 zurück...

Herausforderungen: - wir müssen die alle runterladen (= scraping) - idealerweise brauchen wir das in einer Datei (= coding)

3.10.1 Schritt 1: Links zu csv-Dateien sammeln

- Browser öffnen + Developer-Tools ausklappen (Win/Linux: Ctrl + Shift + I or F12; macOS: Cmd + Opt + I)
- Ganz links in der Ecke auf das Icon mit Rechteck und Cursor klicken (Win/Linux: Ctrl + Shift + C; macOS: Cmd + Opt + C)
- jetzt zu einem csv-Button navigieren und anklicken

3.10.2 Schritt 3: R installieren

R-Download

3.10.3 Schritt 4: RStudio installieren

RStudio-Download

3.10.4 Schritt 5: R-Projekt anlegen

Empfehlung für eine Ordnerstruktur:

```
code
data
  raw
  helpers
  processed
  final
report
img
docs
```

anlegen:

1. Anwendung "Terminal" suchen → öffnen
2. ein paar Befehle ausprobieren:
 - `ls -l` listet alle Ordner und Dateien auf, mit ein paar Metadaten
 - `cd /hier/ein/pfad/zum/ordner` springt zu einem Ordner
 - `pwd` zeigt an, in welchem Ordner man sich gerade befindet
 - alle Ordner wie oben anlegen: `mkdir`

```
mkdir -p code data/raw data/helpers data/processed data/final report/img report/docs
```

3.10.5 Schritt 6: Code kopieren, ausführen, glücklich werden

Code anzeigen

```
# load libraries
library(stringr)

# read html
html <- read_html("https://www.govdata.de/suche/daten/hundebiss-statistik-berlin")

# extract all links
links <- html |>
  html_elements("a") |>
  html_attr("href")

# filter links if they end with ".csv"
csv_links <- links[str_detect(links, ".csv$")]

# download all csv files
for (u in csv_links) {
  download.file(u, file.path(here::here("data/raw"), basename(u)))
}
```

3.11 Langeweile?

3.11.1 Weiterlesen / -hören

- Storytelling:
 - Sven Preger (2024): “Geschichten erzählen : Storytelling für Radio und Podcast”
 - BR kontrovers (2025): “Bauen im Überschwemmungsgebiet, Unterwegs mit der Dorfpolizei und mehr”
- Datenjournalismus:
 - Christina Elmer, Lorenz Matzat (Hrsg.): “Handbuch Daten und KI im Journalismus”
- Journalismus allgemein:
 - Gabriele Hooffacker, Klaus Meier (2026): “La Roches Einführung in den praktischen Journalismus”
 - Maria Ressa (2022): “How to stand up to a dictator”
 - Podcast: Anja Reschke im Hotel Matze (2025): “Welche Aufgabe hat der Journalismus”

3.11.2 Ausprobieren

- immer nett: Was waren die häufigsten Vornamen, z.B. in Rostock oder Berlin

Chapter 4

Daten aufbereiten

Chapter 5

Ich habe Daten – was jetzt?

Worum es heute geht

- **Theorie:**
 - Grundprinzipien der Datenarbeit wiederholen
- **Praxis:**
 - Tabellarische Dateiformate in Tabellenkalkulation laden und aufbereiten
 - Fragen an einen umfangreicheren Datensatz entwickeln
 - Hilfe zur Selbsthilfe: Dokumentation, Tutorial, Debugging
- **Technik:**
 - Dateiformate: csv, xlsx, Tabellen in PDF
 - Tools: LibreOffice, Datawrapper, Tabula, (Firefox-)Developertools, Terminal, RStudio
- **Datenquellen:**
 - Musik, Wein, Bäume

5.1 Beispiel: “Warum sich immer mehr Menschen krankmelden”

von Sophie Menner, Julia Barthel, Kirsten Girschick, Josef Schön

br24.de / tagesschau.de



Hintergrund:

- Grundlage für diese Recherche war die Idee, den Eindruck “irgendwie sind immer mehr Menschen öfter krank, vor allem mit Husten und Schnupfen” näher zu beleuchten. Dafür haben wir Krankenkassen angefragt, ob sie uns Zahlen zu Krankschreibungen (“Arbeitsunfähigkeitsmeldungen”) geben können. Die haben wir schließlich vom BKK-Dachverband bekommen – aufgeschlüsselt nach Geschlecht, Beruf, Landkreis und Krankheitsgruppe (ICD-10-Code).
- Diese Daten haben wir ausgewertet und sehr, sehr viele Arbeitsgrafiken erstellt, um einen Überblick zu bekommen, was relevant sein könnte. Damit haben wir vorsortiert und dann redaktionell die wichtigsten Thesen herausgearbeitet.

Was wir daraus lernen können:

- Gleiche Datengrundlage und Recherche, unterschiedliche Texte, jeweils auf eine andere Zielgruppe zugeschnitten.
- Die Struktur des Textes hängt auch von der (vermuteten) Erwartungshaltung des Publikums ab.
- Das Visualisierungstool beeinflusst auch die Auswahl der Grafiken.

5.2 Übung: Musik – US-Charts

Seit 1958 veröffentlicht das US-Magazin “Billboard” jeden Dienstag die “beliebtesten” Songs – basierend auf Verkäufen, Airplay und Streaming der jeweiligen Erfassungswoche. Alle Top-Titel hat Chris Dalla Riva für seinen Blog und sein Buch zusammengetragen und freundlicherweise als Google-Tabelle veröffentlicht: Billboard Hot 100 Number Ones Database.

→ Welche Geschichten lassen sich darin finden?



Mögliche Fragen

- **Wie viele männliche und weibliche Akteur*innen gibt es:** Artists, Songwriter, Producer? → gruppieren nach Spalte Artist Male (Y) und zählen
- **Was der Zusammenhang zwischen der Dauer auf Platz 1 und dem Overall Rating?** → Spalten D und I, visuell auswerten: Scatter Plot mit Dauer auf x- und Overall Rating auf y-Achse
- **Spiegeln sich globale Ereignisse im Happiness-Score der Charts wieder?** → Spalte AT + Datum visuell vergleichen: Punkte auf x-Achse + eingezeichnete historische Ereignisse
- **Hatte der Vietnamkrieg andere BPM als die 2000er?** → Spalte AQ visuell mit vorher recherchierten und festgelegten Zeitspannen abgleichen: BPM und Zeitspannen, Verlauf in Kurven, ggf. berechnen, indem man für die jeweiligen Zeiten das Integral der Kurven ausrechnet?
- **Wie haben sich Songs hinsichtlich Dancability verändert über die Zeit?** → Spalten AS und C visuell vergleichen: Scatterplot, x-Achse mit der Zeit, y-Achse Dancability; historische Ereignisse ergänzen
- **Im Laufe der Jahre, wie oft sind die Songwriter auch die Artists – gibt es mehr oder weniger Ghostwriter?** → Spalten AF und AG, gruppieren nach Jahr, dann nach Songwriter-Spalte, die dann zählen
- **Über was wird gesungen?** Welche Schlagwörter kommen wann häufiger vor? (z.B. dad vs father) → Spalten CK und CL, pro Jahr nach Wörtern gruppieren (Häufigkeit jedes Worts) und zählen, dann alle "und"-bla-Wörter rausstreichen und dann gucken, was am häufigsten vorkommt und spannend ist
- **Welchen Zusammenhang gibt es zwischen Dancability und Happiness?** → Spalten AS und AT im Scatterplot visuell vergleichen
- **Von welchem (Parent-)Label kommen die meisten Hits und hat sich das über die Zeit verändert?** → Spalten K, L und C, gruppieren nach Jahr und Label und ggf. kleine Labels zusammenfassen
- **Von welchem (Parent-)Label kommen die Hits mit der meisten Dauer auf Platz 1 und hat sich das über die Zeit verändert?** → Spalten K, L, D und C, gruppieren und über die Zeit anschauen
- **Sind die Hits heutzutage für Filme komponiert oder gab es sie bei der Filmproduktion schon und sie wurden gezielt ausgewählt?** → Spalten CS und CT,

neue (Pivot-)Tabelle erstellen: Jahr der Veröffentlichung, nach CS / CT, gruppieren + zählen

- **... wie oben, aber für Fernsehshows: komponiert oder ausgewählt?** → Spalten CU und CV gruppieren und zählen
- **Wie werden die Hits durch Streaming beeinflusst in Bezug auf Länge, BPM etc.?** → zusätzliche Daten zum Streaming nötig
- **In welchem Jahrzehnt gab es die meiste explizite Sprache?** → Spalten CO und C; extra Spalte mit Jahrzehnt anlegen, darauf gruppieren + zählen

Ein Beispiel für eine Musik-Geschichte:

- The Pudding, “Love Songs, RIP”

5.3 Übung: Wein

Der brasilianische Informatik-Professor Rogério Xavier de Azambuja hat 2022 einen großen Datensatz erstellt mit Weinen und “Metadaten”, z.B. wie gern die Weine getrunken werden, woher sie kommen oder zu welchen Gerichten sie passen. Dieser Datensatz ist auf GitHub (kleinere Test-Version mit 100 Einträgen) oder in einem Google-Drive verfügbar. Zum Einstieg eignet sich diese csv-Datei.

→ Was verraten uns die Daten über die Welt der Weine – und welcher wurde am besten bewertet?



Mögliche Fragen

- **In welchen Ländern werden welche Rebsorten besonders viel angebaut?** → Spalten E und K, gruppieren, zählen und sortieren nach höchster Anzahl
- **Gibt es einen Zusammenhang zwischen Region und Acidity (Säuregehalt)?** → Spalten M und I auf interaktiver Karte darstellen, dazu nach Region gruppieren und Acidity auswerten
- **Gibt es einen Zusammenhang zwischen Region und ABV (Alkoholgehalt)?** → Spalten M und G, könnte man ebenfalls auf interaktiver Karte darstellen; dazu nach Region gruppieren und Alkoholgehalt auswerten
- **Gibt es einen Zusammenhang zwischen Alkoholgehalt und Geschmack (Body)?** → Spalten G und H

- **Gibt es einen Zusammenhang zwischen den Grapes und dem Essen, mit dem es harmonized?** → Spalten E und F
- **Welcher “Type” ist am beliebtesten / kommt am häufigsten vor?** → Spalte C gruppieren und zählen
- **Welche Sorte hat die ältesten Jahrgänge? Welche die neuesten? Welche meisten? Welche die wenigsten?**
- **Wie unterscheidet sich der durchschnittliche Alkoholgehalt je nach passendem Gericht?** (Bei welchem Gericht ist es am wahrscheinlichsten, dass man hinterher mehr betrunken ist?)

5.4 Übung: Stadtbaumkampagne Berlin

In Berlin werden im Rahmen der Stadtbaumkampagne jährlich Spenden gesammelt, um neue Bäume zu pflanzen. Mitte März bis Mitte April wurden bereits viele Bäume gepflanzt, die Senatsverwaltung für Mobilität, Verkehr, Klimaschutz und Umwelt veröffentlicht hier die Baumlisten.


→ **Welche Geschichten verstecken sich in den Listen?**



Mögliche Fragen

- **Was wird wo gepflanzt?** → Baumarten zusammenfassen nach Straßen
- **Was wurde am meisten neu gepflanzt?** Allgemein und nach Stadtteilen → Baumarten (+ Stadtteile gruppieren und zählen)
- **Welcher Stadtteil hat am meisten Diversität an Pflanzen?** → zuerst Diversität definieren, z.B. prozentualer Anteil
- **Wie viel Durchmischung gibt es pro Straße?** → ähnlich wie “Diversität”
- **Wo / in welcher Straße wird nur eine Baumart gepflanzt?** → prozentualer Anteil = 100%
- **Welche Bäume sind da schon – erhöht man die Diversität mit der Neupflanzung?** (braucht zusätzliche Daten, welche Bäume schon vorhanden sind)
- **Wie dicht ist die Neubepflanzung?** → nach Hausnummer-Abständen berechnen, aber eher unvollständig

5.5 Wo kann man nach Daten stöbern?



- “Data Is Plural”, leider eingestellter Podcast + Newsletter, Archiv
- GitHub, z.B. Suche nach “awesome dataset”
- TidyTuesday, wöchentliche Challenge, die sich vor allem auf R bezieht
- kaggle as a very popular platform for data science (but I don’t like it, to me it seems often a bit... contextless?)
- reddit
- Our World in Data
- international / Ländervergleich: generell UN-Daten
 - Weltgesundheitsorganisation WHO
 - Humanitäre Daten der UN-Organisation OCHA

Chapter 6

Daten sammeln

Chapter 7

Ich habe eine Frage, aber keine Daten


Worum es heute geht

- **Theorie:**
 - Daten scrapen
- **Praxis:**
 - Browser: Developer-Tools verstehen und nutzen
 - Code in RStudio anlegen und ausführen
- **Technik:**
 - RStudio
 - Datenformate: JSON und WMS
- **Datenquellen:**
 - Websites (Verkehrsgesellschaft, Drogeriemarkt)
 - Öffentliche Einreichungen (Bayerisches Landesamt für Umwelt)

7.1 Beispiel: “Freie Plätze sind rar: Die Lage in bayerischen Frauenhäusern”

2026: br24.de + CORRECTIV.Lokal → ndr.de, KATAPULT Sachsen, SWR...

2023: correctiv.org



→ Original-Website: frauenhaus-suche.de

7.2 Übung: Defekte Aufzüge / Rolltreppen in München



Website der Münchner Verkehrsgesellschaft MVG

Schritt 1: Was wünscht sich die Website-Betreiberin – was dürfen wir automatisiert auslesen? → robots.txt

Schritt 2: Wir schauen uns um: Was brauchen wir? → Developer-Tools öffnen (Rechtsklick oder Tastenkombination, je nach Browser + Betriebssystem) → *Tipp: Interessant ist oft "Network" → XHR*.

Was ist XHR?

Webseiten bestehen technisch aus HTML-Code. Hier haken "echte Programmierer" gern ein und korrigieren: HTML ist aber nur eine Auszeichnungssprache, das hat nichts mit Code zu tun.

Stimmt: HTML heißt HyperTextMarkupLanguage und kann vor allem verschiedene Elemente auf einer Website darstellen: Eine Überschrift auf dem höchsten Level wird markiert mit `<h1>` am Anfang und `</h1>` am Ende, eher eine Unterüberschrift mit `<h2>` und `</h2>`, eine Unterunterüberschrift mit `<h3>` und `</h3>` und so weiter...

Links sind oft interessant, die sind gekennzeichnet mit `<a href="https://example.com">Hier klicken</a>`. Hier klicken steht dann in Link-Formatierung auf der Website. Der Teil in Anführungszeichen

hinter href= ist die URL, wo man hingeleitet wird.

Wenn jetzt eine Website was “können” soll, sich also anpassen oder Daten laden, dann nutzt man dafür JavaScript. Das ist eine Programmiersprache, die beispielsweise “wenn, dann...”-Befehle ausführen kann: “Wenn drei Sekunden vorbei sind, dann zeigst du ein neues Bild an, lieber Browser.” Oder eben: “Wenn dieser Code geladen wird, dann hole bitte die Daten im Hintergrund von folgender Website.”

Und solche Daten werden dann im Hintergrund übertragen, ohne dass die Website neu geladen werden muss, mittels eines “XHR”, oder ausgeschrieben “XMLHttpRequest”. Der Server bekommt also eine Anfrage: Ey, gib mal Daten. Und zwar in verschiedenen Formaten, XML steht im Namen, kann aber auch JSON sein.

Schritt 3: Wir schauen uns die reinen Daten im Rohformat “JSON” an: Schnittstelle

Schritt 4: Wir speichern uns die Daten ab, um sie lokal weiterzuverarbeiten.

R-Code ausklappen

```
library(jsonlite)
library(rrapply)

x <- fromJSON("https://www.mvg.de/.rest/mvgZoom/api/stations", simplifyVector = FALSE)

df <- x |>
  rrapply(how="melt")
```

7.3 Übung: Drogerie-Produkte

Wie viel kosten 100ml Sonnencreme im Durchschnitt und was ist der niedrigste Preis für 100ml Sonnencreme?



Code anzeigen

```
url <- "https://product-search.services.dmttech.com/de/search/crawl?query=Gesicht&allCategories.id=search&sort=editorial_relevance&type=search-static&enablePharmacy=true"
```


```
x <- fromJSON(url, simplifyVector = FALSE)

df <- x |>
  rrapply(how="melt")
```

7.4 Übung: Windkraft Bayern

Wenn es deutschlandweit um das Thema Windkraft geht, steht Bayn immer wieder besonders schlecht da (z.B. br24.de).

Aber wie ist die Situation wirklich? **Welche Rolle spielt Strom aus Windkraft für Bayern?**



Schritt 1: Daten suchen

Link zu Daten

<https://www.govdata.de/suche/daten/strom-aus-windenergie-statistik-bay>

Schritt 2: Datenformat verstehen

Was ist WMS?

WMS steht für “Web Map Service” und ermöglicht es, Kartendaten von Servern abzurufen.

Schritt 3: Software QGIS öffnen und WMS-Layer hinzufügen

Layer → Add Layer → Add WMS/WMTS Layer → “New” → URL einfügen → OK

Chapter 8

Ein Projekt strukturieren

Worum es heute geht

- **Theorie:**
 - ein Projekt strukturieren
- **Praxis:**
 - Projekt definieren
 - Probleme finden und beheben
- **Technik:**
 - Tabellenkalkulation, R oder Python
- **Datenquellen:**
 - eigene

Chapter 9

Heute geht's um eure Projekte!

Dazu noch drei Punkte:

1. Geschichten in Daten finden – Pfade zum Erfolg
2. Zeitmanagement & Dokumentation
3. Kleine Datenquellenkunde

9.1 1. Geschichten in Daten finden – Pfade zum Erfolg

Kleiner Reminder der verschiedenen Dimensionen, in denen sich eine Geschichte verstecken kann:

1. Status quo – Verhältnisse zwischen Gruppen
2. Räumliche Verteilung
3. Zeitlicher Verlauf

→ Dimensionen nicht vermischen, sondern jeweils die interessantesten Punkte finden:

1. Welche Trends zeichnen sich ab?
2. Wo gibt es Ausreißer?

9.2 2. Zeitmanagement & Dokumentation

Wir arbeiten "iterativ", also Schritt für Schritt, im Kreis, vor und zurück. Klingt fancy, aber was heißt das?

Tipp: Pomodoro-Technik

25 Minuten konzentriertes Arbeiten (Versinken ist okay)
5 Minuten Pause – no matter, what

- vor der Pause ggf. Gedanken kurz aufschreiben (max. zwei Sätze)
- nach der Pause Reflexion mit frischem Blick: auf welchem Weg bin ich?

9.2.1 Dokumentation – Gedanken mitschreiben

Ist wie Tagebuch schreiben: Fühlt sich währenddessen überflüssig an, weil “ich weiß ja, was ich im Kopf hab”. Wird über die Zeit aber sehr wertvoll, weil man hinterher nachvollziehen kann, wo und warum man angefangen hat.

Tipp: Markdown verwenden – das ist schnell erlernbar und hinterher funktional einsetzbar. Die wichtigsten Symbole:

für die erste Überschrift

für die zweite Überschrift

dieser Text ist ****fett****

dieser Text ist _unterstrichen_

So sieht ein [Link](example.org) aus

- und das
- ist eine
- Aufzählung

1. bzw. eine
2. nummerierte
3. Aufzählung

technische Dinge wie ``Code`` kann man in sogenannte ``Backticks`` schreiben, dann bleibt es

(oder drei mal ``` für ganze Code-Blöcke)

9.3 3. Kleine Datenquellenkunde



9.3.1 Wer könnte das wissen? – Datenquellen finden

1. Gibt es jemanden, der diese Daten erheben **muss** (z.B. offizielle Stellen)?
2. Gibt es jemanden, der diese Daten erheben **will** (Wissenschaft, NGOs, Datennerds)?

9.3.2 offene Daten

- Statistisches Bundesamt: [destatis.de](https://www.destatis.de)
- Statistische Landesämter: [regionalstatistik.de](https://www.regionalstatistik.de)
- Statistische Landesämter mit eigenen Websites (manchmal anders durchsuchbar, Daten anders gebündelt)
- Portal für alle möglichen Datensätze aus öffentlichen Behörden in Deutschland: [govdata.de](https://www.govdata.de)
- European Data Portal
- EU Open Data Portal
- Eurostat Database
- Weltbank
- IMF
- OECD
- UN Data
- Deutscher Wetterdienst
- NASA
- Europäische Behörden, z.B. European Environment Agency (EEA): [eea.eu](https://www.eea.eu)

9.3.3 selbst erhobene Daten

beispielsweise durch eigene Messungen

9.3.4 exklusive Daten

- Behörden:
 - Arbeitsagentur

- Umweltbundesamt
- Verbände:
 - Marburger Bund,
 - Mieterbund
- **Wissenschaft:**
 - Sozioökonomisches Panel (SOEP)
- **NGOs und Vereine:**
 - Greenpeace
 - fragdenstaat.de
- **Vergleichsportale:**
 - Check24
 - Verivox

9.3.5 gescrapte Daten

beispielsweise durch regelmäßiges, automatisiertes Speichern

9.3.6 Informationsfreiheitsgesetz (IFG)

- Recht auf Zugriff auf amtliche Informationen für alle
- Alle Bundesbehörden sind zur Auskunft verpflichtet
- Recht auf Akteneinsicht
- Landes-IFGs prüfen
- Weitere Infos:
 - Fragen und Antworten zum Informationsfreiheitsgesetz
 - FragDenStaat.de

Ob es wirklich einen Rechtsanspruch auf Daten gibt, ist in vielen Fällen fraglich – aber immer einen Versuch wert!

9.4 Parlamentarische Dokumente (Drucksachen)

- Kleine Anfragen (☒ RIP kleineAnfragen.de)
- Schriftliche Fragen
- Anträge
- Gesetze(sentwürfe)
- Plenarprotokolle
- Datensätze zu Abstimmungsverhalten und Stammdaten

Grundsätzliche Fragen an jeden Datensatz

- **Urheber, Herkunft, Motiv:** Wer hat die Daten wie erhoben? (Wer profitiert?)
- **Transparenz:** Was erfahre ich an Zusatzinfos zu den Daten?

- **Aktualität:** Sind die Daten aktuell? Überprüfung?
- **Relationen:** Welche Datenpunkte kann ich miteinander vergleichen?
- **Relevanz:** Welche Daten sind wirklich relevant?
- **Abgleich:** Welche alternativen (besseren) Datenquellen gibt es zur Überprüfung?

Interner Link zu Dokumenten

Chapter 10

Projekt ist fertig – wir blicken zurück

Worum es heute geht

- **Theorie:**
 - Wie bewertet man ein Projekt?
- **Praxis:**
 - Qualitätskriterien anwenden
- **Technik:**
 - Datawrapper
- **Datenquellen:**
 - eigene

10.1 Wann ist ein Projekt abgeschlossen?

!–

Das Problem: Besser geht immer.

“Fertig” ist also vor allem, wenn

- a) eine abgegrenzte, vorab formulierte Frage beantwortet wurde.
- b) die verfügbare Zeit abgelaufen ist.

10.2 Besser werden

!–

10.2.1 Die Sicht von außen: Feedback geben

Qualitätskriterien für eine gute Datengeschichte

1. Lese ich die Geschichte gerne?
2. Sind alle formalen Kriterien erfüllt? (Korrekte Quellenangabe, angemessene Überschrift, verständliche Farbgebung und Legende in Grafiken etc.)
3. Können wir noch nachvollziehen, wie die Daten verarbeitet wurden?
4. Ist die Methodik angemessen und die Daten korrekt?
5. Sind die Grafiken gut gewählt für die Aussage?

10.2.2 Die Sicht von innen: Manöverkritik

10.2.2.1 1. Was ist gut gelaufen?

- a. Was beherrsche ich (gerade) gut? Sollte ich das dokumentieren, damit ich es auch in Zukunft kann?
- b. Was wirkte wie glücklicher Zufall – und was kann ich daraus lernen?

10.2.2.2 2. Was waren meine größten Herausforderungen?

- a. Welche davon konnte ich lösen, was mache ich nächstes Mal anders?
- b. Welche davon konnte ich nicht lösen, womit sollte ich mich weiter beschäftigen?

Chapter 11

Webscraping

Worum es heute geht

- **Theorie:**
 - Wie extrahieren wir Informationen aus HTML-Code?
- **Praxis:**
 - Code schreiben
- **Technik:**
 - Verschiedene Scraper-Libraries für R / Python
- **Datenquellen:**
 - Scraping-Übungsseite
 - Museen Hamburg
 - Fête de la musique Berlin
 - dm

11.1 Webscraping – was ist das?

Wir haben uns schon angeschaut, wie man Daten sammeln kann. Dazu haben wir den Netzwerk-Verkehr im Browser angeschaut – sowie entsprechenden Code, um einen Browser nachzuahmen.

Heute geht's tiefer: In den bisherigen Beispielen hatten wir Glück, dass die Daten gut aufbereitet vorlagen, in Form von json-Files. Das ist natürlich nicht immer so.

Grob kann man die übrigen Fälle unterteilen in:

1. Informationen liegen gut sichtbar auf einer Webseite vor – und können daher gut ausgelesen werden. Manchmal hat man eine ganze Liste von Webseiten, von denen man die gleichen Informationen strukturiert speichern möchte.

2. Informationen sind zwar auf einer Webseite sichtbar, aber erst nur teilweise und werden nachgeladen, indem man weiterscrollt oder auf Knöpfe drückt. Wir brauchen also Interaktivität.

Diese beiden Fälle schauen wir uns nacheinander an.

11.2 1. Informationen sind auf einer Webseite verfügbar.

Auf einer einfachen Website liegen Informationen immer strukturiert vor. Die Frage ist also vor allem, ob uns die technische Struktur hilft.

11.2.1 Tabellen

Vor allem Tabellen sind dabei sehr komfortabel, weil im html-Code eine feste Struktur für Tabellen definiert ist:

```
<TABLE summary="This table charts the number of cups of coffee consumed by each senator"
<CAPTION>Cups of coffee consumed by each senator</CAPTION>
<TR>
  <TH>Name</TH>
  <TH>Cups</TH>
  <TH>Type of Coffee</TH>
  <TH>Sugar?</TH>
<TR>
  <TD>T. Sexton</TD>
  <TD>10</TD>
  <TD>Espresso</TD>
  <TD>No</TD>
<TR>
  <TD>J. Dinnen</TD>
  <TD>5</TD>
  <TD>Decaf</TD>
  <TD>Yes</TD>
</TABLE>
```

Als Tabelle sieht das dann so aus:

Cups of coffee consumed by each senator

Name

Cups

Type of Coffee

Sugar?

T. Sexton

10

Espresso

No

J. Dinnen

5

Decaf

Yes

-

Fun fact: Dieses Beispiel hab ich mir nicht ausgedacht, sondern es kommt vom "World Wide Web Consortium", aus der Beschreibung des html-Standards. Kann man hier alles nachlesen

Beispiel: <https://www.scrapethissite.com/pages/forms/>

```
library(rvest)

page <- read_html("https://www.scrapethissite.com/pages/forms/")

raw_table <- page |>
  html_element("table.table") |>
  html_table()
```

11.2.2 Andere, klar definierte Elemente

Praktisch, weil sie oft relevant und gut markiert sind:

- `<h1>`, `<h2>`, `<h3>`...: Überschriften
- `<a>`: Links
- `<li>`: "List items", als Aufzählungen, entweder mit Gedankenstrichen (unordered list: `<ul>`) oder als nummerierte Liste (ordered list: `<ol>`)
- `<div>`, `<section>`...: generelle Container / Abschnitte...

Oft gibt es davon aber mehrere. Deshalb sind sie in der Regel in Klassen unterteilt, die mit in der spitzen Klammer angegeben sind, z.B. `<h1 class="Postanschrift">`.

Praktisch für uns: aus der Kombination des Typs und der Klasse können wir ziemlich gut navigieren.

11.2.3 Mehrere Webseiten (mit gleicher Struktur)

Listen von Webseiten bekommt man auf verschiedenen Wegen:

11.2.3.1 1. es gibt eine Übersicht der Webseiten (ggf. auch gescraped)

Beispiel: <https://museumsdienst-hamburg.de/museen-in-hamburg/>

```
library(rvest)
library(tidyverse)

html <- read_html("https://museumsdienst-hamburg.de/museen-in-hamburg/")

html |>
  # html_elements("h3") |>
  html_elements(".link-invisible") |>
  html_text()

museum_links <- html |>
  html_elements(".post-item") |>
  html_attr("href")

for (museum_link in museum_links){
  print(str_glue("Processing museum with url: {museum_link}"))

  museum_html_temp <- read_html(museum_link)

  museum_name <- museum_html_temp |>
    html_element("h1") |>
    html_text()

  print(museum_name)

  museum_oeff <- museum_html_temp |>
    html_elements(".infobox") |>
    pluck(3) |>
    html_elements("p") |>
    pluck(2) |>
    html_text()

  print(museum_oeff)
}
```

11.2.3.2 2. “Weiterblättern”

Wir schauen uns nochmal die Scraping-Übungsseite an: [<https://www.scrapethissite.com/pages/forms/>]. Hier sind die einzelnen Informationen auf vielen Seiten verteilt. Wir müssen also einmal durch alle Seiten durchgehen. Sobald wir auf die zweite Seite blättern, verändert sich die URL zu: https://www.scrapethissite.com/pages/forms/?page_num=2. Wir sehen, dass es insgesamt 24 Seiten gibt. Die URL lässt darauf schließen, dass

man `page_num=` um jede Seite ergänzen kann.

11.3 2. Informationen sind nur teilweise sichtbar, müssen nachgeladen werden.

Auch hier gibt es vor allem zwei Möglichkeiten:

1. Scrollen bis zum Ende der Seite lädt neue Informationen
2. Klick auf Buttons wie "Weiterlesen" oder "mehr laden" lädt mehr

Für diese Aufgabe eignet sich Python als Programmiersprache mit der Library Playwright. Für die Installation braucht es zwei Schritte: Erstens muss man die Library installieren, z.B. mit `pip install playwright`. Und zweitens braucht es einen entsprechenden Browser, der "ferngesteuert" werden kann. Diesen installiert man mit `playwright install`.

11.3.1 Mehr laden durch Scrollen

Beispiel: Programm der fête de la musique Berlin

11.3.2 Mehr laden durch Klick auf Button

Beispiel: Viele Produkt-Seiten wie zum Beispiel Sonnencreme, "Mehr laden"

Chapter 12

Die Tools im Überblick

Umgebung	Tool	Einsatzzweck	Website	Nachlesen
R	rvest	schnell loslegen, überschaubarer Umfang	☒	☒
R	rplaywright	bisschen umfangreicher	☒	☒
Python	pandas	Tabelle in <i>(read_html)</i> HTML-Struktur	☒	☒
Python	requests	Website abrufen	☒	☒
Python	beautifulsoup4	Informationen aus HTML-Struktur extrahieren	☒	☒
Python	Playwright		☒	☒
Python	Selenium		☒	☒
Python	Puppeteer		☒	☒

Mögliche Suchbegriffe für weitere Tools: “Scraping” (Informationen von Websites sammeln), “Parsing” (Zeichenketten auswerten), “Crawling” (Websites durchgehen), “Browser Automation”, “Web Testing”

12.1 Wichtige Punkte

- robots.txt lesen!

- Webscraping ist immer ein wenig unberechenbar – und wird es immer mehr: Webscraping wird immer aufwendiger, weil immer mehr Bots und Crawler unterwegs sind, um das Internet maschinell zu verarbeiten – insbesondere für verschiedenste “KI”-Anwendungen.
- Mittelweg finden: Wie bekomme ich schnell die Informationen, die ich brauche, ohne den Server zu sehr zu belasten? Anzahl der Anfragen beschränken!

Chapter 13

Kartendaten

Worum es heute geht

- **Theorie:**
- **Praxis:**
- **Technik:**
- **Datenquellen:**

13.1 Webscraping – was ist das?

Chapter 14

Storytelling

tbd

Chapter 15

Dramaturgie

tbd

Chapter 16

Text

tbd

Chapter 17

References

- Harzer, Friedmann. 2017. *Literarische Texte Interpretieren : Lyrik - Prosa - Drama*. Vol. 4634. UTB. Paderborn ; Wilhelm Fink.
- Sengers, Luuk, and Mark Lee Hunter. 2018. *Drehbuch Der Recherche: Das Verborgene Szenario: Journalistische Recherchen Planen Und Organisieren*. Nr-Werkstatt 25. Berlin: Netzwerk Recherche.

